COMMERCIAL PROPERTY MULTI-AGENT

项目总开发路线与进度手册

Agent-first · Notability 阅读批注版

把一个跨系统业务问题，变成一条可运行、可解释、可评测的 Agent 工作流。

10	03	01
正式开发 Prompt	对照基线	核心调查场景

阅读方式

先看第 4 页路线总览；执行时打开对应步骤页；每次验收后在第 15 页更新手写进度。PDF 自带目录书签。

进度快照说明

Prompt 1 初稿已交付，首轮待修正；其余 9 步未开始。
本册不是新的验收结果，也不按步骤数量估算代码完成百分比。

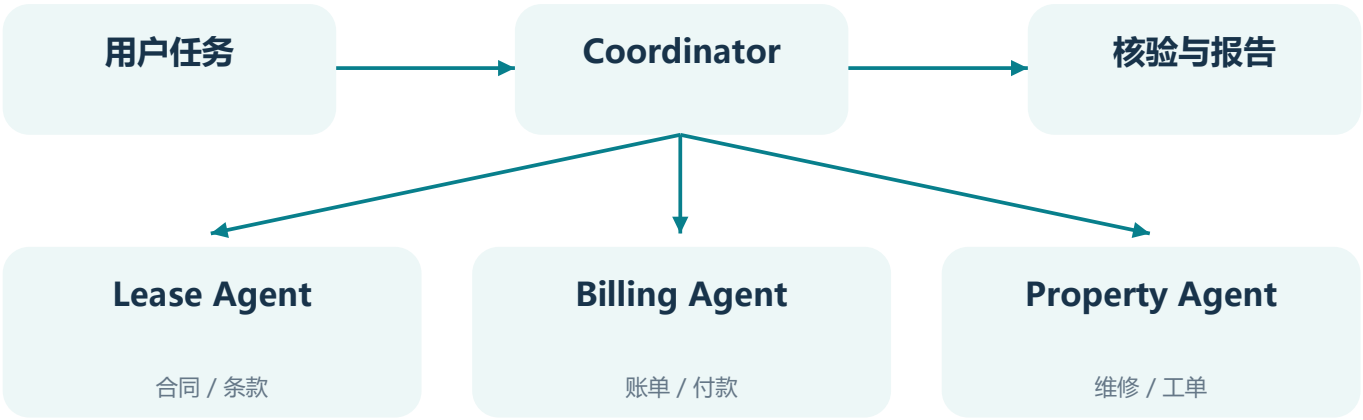
01 / 项目理解

我们到底要完成什么

一个可配置的企业级多 Agent 工作流系统，以商业地产争议调查验证 AI 工程能力。

A-301 的调查任务

近三个月租金不同，空调反复维修，还有减免诉求。系统核对合同、账单、付款和工单，输出事实、证据、缺失信息与审核草案。



共享底座：受控工具 • 权限 • 数据真值 • 证据 • Trace

能调用	正确选择工具和参数	**能协作**	独立 Agent 按能力调度
能追溯	引用回到原文和记录	**能恢复**	超时、重启与审批
能评测	与简单方案公平对照	**能复现**	环境、数据、运行有据

范围边界：保留历史设计；当前不开发完整 ERP、完整财务引擎、招商 BI 或真实调账接口。

02 / 协作与数量

一次 Prompt 怎样变成进度



返修不占下一项编号；Git 提交由你确认后执行。

10 次正式任务，是当前 MVP 的完整排期

理想：10 次正式 Prompt（含已发送的 Prompt 1）。
当前：1 次已发 + 1 次已识别返修 + 9 次后续 = 预计 11 次。
后续若继续返修或增加范围，实际发送数相应增加。

每轮交付我都检查什么?

03 / 可点击步骤导航

十步路线，一页掌握全局

01 **基线与 8 题** 待修正
Prompt 1 · 预计 Task 006 · 定范围

02 **Runtime 与工具执行** 未开始
Prompt 2 · 预计 Task 007 · 打底座

03 **LangChain 真实工具调用** 未开始
Prompt 3 · 预计 Task 008 · 接模型

04 **LangGraph 多 Agent 调查** 未开始
Prompt 4 · 预计 Task 009 · 跑协作

05 **PostgreSQL 业务真值** 未开始
Prompt 5 · 预计 Task 010 · 接数据

06 **合同 PDF 与 RAG** 未开始
Prompt 6 · 预计 Task 011 · 查知识

07 **持久恢复与人工审批** 未开始
Prompt 7 · 预计 Task 012 · 补可靠性

08 **40 题与三基线评测** 未开始
Prompt 8 · 预计 Task 013 · 做测量

09 **FastAPI 与轻量演示页** 未开始
Prompt 9 · 预计 Task 014 · 可演示

10 **总验收与项目展示** 未开始
Prompt 10 · 预计 Task 015 · 可交付

预计任务号尚未全部登记；新增独立任务时按 docs 编号规则顺延。上述是开发顺序，不是工期比例。

PROMPT 1 / 预计 TASK 006

01 定基线、接口与 8 题

统一目标、接口与正确答案

依赖 起点：已确认的 Agent-first 方向

本步交付

方向 ADR、MVP 范围、Runtime 契约规格、共享合成数据、8 个开发样例、评测方案。

验收标准

金额与引用可独立核对；超时/权限/审批用例无自相矛盾；Graph 分支闭合；三基线不因预设路由而被偏置判分。

当前状态

核心金额和实体引用检查通过，57 项旧骨架自检通过；仍有 6 组规格问题，见 Review。先发送 1-R1，不进入 Prompt 2。

解决的问题

保证 DeepSeek 和 Codex 对目标、输入输出和正确答案有相同理解。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 2 / 预计 TASK 007

02 Runtime 与受控工具执行

离线也能验证受控执行

依赖 Prompt 1 验收。

本步任务

• 建立可复现依赖声明、pytest 与最小运行入口，不堆入尚未使用的依赖。
• 实现已收敛的 Pydantic 契约、可信上下文、Evidence 和结构化结果。
• 修复 Registry、配置一致性、deadline、PARTIAL/SKIPPED 汇总问题。
• 实现 Tool Registry / Executor：白名单、权限、参数/结果校验、timeout、有限重试、共享预算与 Trace。
• 加载 fixture，提供 Lease/Billing/Property 的只读测试工具；注入 Fake Model，零网络测试。

验收标准

工具拒绝越权与非法参数；无任意 SQL/代码入口；Decimal 核对正确；并发预算不超发、重放不重复计数；原测试与新测试通过。

你能看到

命令行发起受控工具任务，返回结构化结果和调用记录。此时不声称已接真实模型或完成多 Agent。

检查点

Runtime/工具可单独测试，后续模型和数据库通过接口接入。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 3 / 预计 TASK 008

03 LangChain 与真实模型工具调用

模型真正通过工具完成任务

依赖 Prompt 2。

本步任务

扩展已有 LLM 适配层，接入 LangChain 与 DeepSeek；实现有限轮次工具调用循环、参数解析、工具结果回传、最终结构化输出和 usage 记录。实现单 Agent + Tools 基线的最小版本。

验收标准

真实模型至少完成一次「发起工具调用 > 受控执行 > 读取结果 > 回答」的端到端任务；超限与模型错误明确退出。离线测试通过不等于真实集成通过；真实调用须有记录且在用户同意的预算内，缺密钥时不能伪造通过。

你能看到

一个 Agent 真正通过工具查账或查条款，能检查工具名、参数、返回值、token 和答案引用。

检查点

Fake 与真实 Provider 可切换，密钥不入仓库。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 4 / 预计 TASK 009

04 LangGraph 与三类调查能力

第一条多 Agent 调查闭环

依赖 Prompt 2、3；此时允许继续使用固定数据。

本步任务

实现 Lease、Billing、Property 独立 Agent；Coordinator 按能力规划；LangGraph 条件分支、动态选择子任务、并发合流；Verifier 校验事实与引用；一次有上限补查；形成调查报告。

验收标准

A-301 案例能返回合同、账单、付款、工单证据；简单查询走短路径；禁用非必要 Agent 可降级；必要能力缺失明确报告；合流等待预期子任务；归并与预算不受到达顺序影响。此阶段的图恢复/审批尚不能冒充已完成。

你能看到

第一次真实多 Agent 调查演示，含分支、并发与带证据报告。

检查点

图只依赖协议和工具，数据库/RAG 接入不重写所有 Agent。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 5 / 预计 TASK 010

05 精简 PostgreSQL 与业务真值

业务数据有可靠真值来源

依赖 Prompt 4；按已实际用到的查询反推表结构。

本步任务

确定并实施最小 Schema、SQLAlchemy、Alembic、只读 Repository/Service；导入固定合成业务数据。保留旧 14 表设计，记录本次选择及映射差异。

验收标准

独立测试库可由迁移与种子数据重建；同一输入在 fixture 与 PostgreSQL 返回等价结果；项目隔离、冲销排除和余额计算通过；业务工具无写入权限。无需先实现完整核销/计费引擎。

你能看到

同一工作流的数据来源从 JSON 换成真实 PostgreSQL，Agent 调用契约保持稳定。

检查点

只操作明确的测试数据库，迁移回滚在可重建库验证，不删除其他数据库或原数据。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 6 / 预计 TASK 011

06 合同 PDF、RAG 与证据验证

每条合同引用都能回到原文

依赖 Prompt 4 的证据契约、Prompt 5 的文档元数据。

本步任务

制作独立的合成合同 PDF；解析、分段、索引和受控检索；保留文档版本、页码、原文定位。先实现可评测的最小检索路径，召回不足再选择混合检索或 rerank，不复制其他项目的数据。

验收标准

引用能定位到实际 PDF 原文；不存在的条款明确无结果；草案与签署文件区分；文档内指令不能扩大权限或改变工具策略；同一版本能重建索引。模拟页码与真实页码的测试分开。

你能看到

点击/查看合同证据即可在 PDF 找到出处，回答不只依据预写片段。

检查点

文档与索引版本独立，重建索引不影响业务账单。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 7 / 预计 TASK 012

07 持久恢复与人工审批

重启后继续，审批有边界

依赖 Prompt 4-6。

本步任务

接持久 checkpointer；明确 thread/run/request/trace 标识；审批独立节点暂停；重新授权后恢复；绑定草案版本；处理拒绝、过期、重复恢复与并发恢复。补齐超时、权限撤销、预算耗尽等故障注入。

验收标准

进程退出后能恢复指定任务；权限撤销或版本不匹配拒绝恢复；未经批准不继续审批路径；重复恢复不重复产出动作；批准也只形成「已批准草案」，不真实调账或派单。

你能看到

调查暂停 > 人工决定 > 重启后继续；失败路径有可解释结果。

检查点

checkpoint 与真实业务数据分开管理，不宣称外部副作用恰好一次。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 8 / 预计 TASK 013

08 三基线与 40 题正式评测

用结果说明收益与代价

依赖 Prompt 3-7；此前每一步已持续运行开发样例和测试。

本步任务

把已有开发 runner 补成完整评测器；形成建议 40 题的数据集（8 道开发题加 32 道独立保留题）；完成 Deterministic / Single Agent / Multi-Agent 三种实现；统一权限、工具与全任务预算；输出逐题结果和汇总。

验收标准

事实/金额/引用/审批断言与人工量表分开；路由效率不冒充答案正确率；报告失败题、延迟、模型/工具调用及全任务 token/成本口径。真实模型按冻结配置重复测量并记录，不用 Fake 结果宣称真实质量或成本。不预设多 Agent 赢。

保留题在开发冻结后生成或封存，先冻结评分规则；运行后不拿保留结果调 Prompt。为了统计随机性可以按预先固定次数重复运行，同一批次不调配置。

你能看到

可检查的三基线报告：哪些题多 Agent 有价值，哪些题普通工具更合适，代价是多少。

检查点

报告绑定代码、数据、模型、配置和评分版本；改变配置后另生成实验，不覆盖历史结果。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 9 / 预计 TASK 014

09 FastAPI 与轻量演示页

让任务、证据和轨迹看得见

依赖 Prompt 7 的任务生命周期；Prompt 8 的输出格式。

本步任务

提供任务提交、状态查询、事件/Trace 查看、审批恢复接口；一个轻量页面展示输入、报告、证据、未解决问题及审批状态。建议 FastAPI + 简单同源 HTML/JS，避免完整 React 管理后台；具体实现以该任务 Prompt 为准。

验收标准

可信身份由服务端注入，用户请求不能自报权限；任务间隔离；可看到审批暂停与恢复；接口错误可追踪；展示层不直接访问数据库或调用 Agent 内部类。

你能看到

可以现场演示的界面，不再依靠查看终端日志理解任务。

检查点

界面和 API 为核心 WorkflowRunner 的适配层，删除展示层不会破坏 CLI 与评测。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

PROMPT 10 / 预计 TASK 015

10 最终验收与项目展示

交付可以复现与解释的作品

依赖 前 9 项已验收。

本步任务

在独立环境复现；运行完整测试和冻结评测；整理 README、环境变量模板、启动/种子数据/索引/测试/演示命令、架构图、Trace 样例、失败示例、演示脚本和技术取舍；清理「仅计划却写已实现」的表述。制作可展示的版本候选。

验收标准

新环境按文档可复现；A-301 成功、故障、审批案例可演示；40 题对照有结果文件；切换/禁用 Agent 有回归证据；未提交敏感数据；明确限制与后续工作。不自动提交、打 Tag、发布或部署，需用户另行确认。

你能看到

一套能运行、能演示、能解释、能据实写进简历的项目作品。

检查点

提交建议与发布候选材料；实际 hash/Tag 只有操作真实发生后记录。

☐ DeepSeek 已交付　☐ Codex 已验收　☐ Git 已记录

本步批注 / 验收日期： _____

04 / 在 Notability 手写更新

我的进度总表

快照：Prompt 1 待修正，其余未开始。空白勾选供你按实际验收更新，不预填已完成。

步骤	交付主题	已交付	已验收	已提交	日期
01	基线与 8 题	☐	☐	☐	
02	Runtime 与工具执行	☐	☐	☐	
03	LangChain 真实工具调用	☐	☐	☐	
04	LangGraph 多 Agent 调查	☐	☐	☐	
05	PostgreSQL 业务真值	☐	☐	☐	
06	合同 PDF 与 RAG	☐	☐	☐	
07	持久恢复与人工审批	☐	☐	☐	
08	40 题与三基线评测	☐	☐	☐	
09	FastAPI 与轻量演示页	☐	☐	☐	
10	总验收与项目展示	☐	☐	☐	

返修记录

任务号：_____ 返修序号：_____ 复验结果：_____

实际已发送 Prompt：_____ 次 下一次：_____

状态与提交独立：验收通过不代表已提交；提交 hash 以 Git 实际记录为准。

05 / 最终验收与备忘

什么时候可以说「项目完成」

- [ ] **能运行** 独立环境按 README 完成启动、数据准备与测试。
- [ ] **能调查** A-301 的事实、差异、来源与缺失项形成完整报告。
- [ ] **能解释** 文档引用回到实际 PDF；金额回到确定性计算与记录。
- [ ] **能恢复** 演示超时、重启、拒绝审批及授权恢复。
- [ ] **能替换** 独立配置、禁用或替换 Agent 后相关回归通过。
- [ ] **能比较** 40 题三基线结果、失败明细、延迟与全任务代价可检查。
- [ ] **能展示** 轻量页面、架构说明、Trace 样例和演示脚本完整。

当前下一步

DeepSeek 执行 Prompt 1-R1，Codex 复验任务 006；通过后进入 Prompt 2 的 Runtime 实现。

来源与版本

主要来源：docs/product/PROJECT_DEVELOPMENT_ROADMAP.md
方向依据：PROJECT_REFOCUS_AGENT_FIRST_V1.0.md
验收快照：2026-11-03_task006_review.md
本册于 2026-11-04 排版导出；技术步骤来自路线 V1.0。

我的下一步 / 日期